# Guía de estudio – Unidad II

## Recolección y procesamiento de datos + Formulación del modelo matemático

**Asignatura:** Simulación
**Docente:** Msc. Lic. Andrés Grover Albino Chambi
**Modalidad:** Aula invertida
**Unidad:** Unidad II
**Temas:**

- 2.2 Recolección y procesamiento de datos.
- 2.3 Formulación del modelo matemático.
- Principio de parsimonia.
- Verificación y validación.
- Pruebas de bondad de ajuste.

# 1. Propósito de la guía

Esta guía tiene como objetivo que el estudiante sea capaz de:

1. Formular correctamente un problema de simulación.
2. Identificar el sistema, las variables y los supuestos.
3. Proponer un proceso de recolección de datos con tamaño de muestra adecuado.
4. Procesar datos mediante estadística descriptiva.
5. Detectar valores atípicos usando Z-Score.
6. Aplicar pruebas de bondad de ajuste para decidir si una distribución es razonable.
7. Formular un modelo matemático parsimonioso.
8. Diferenciar verificación y validación del modelo.

Este material está diseñado para estudiarse antes de la sesión presencial. En clase se resolverán dudas, se discutirá la interpretación de resultados y se preparará el primer parcial.

# 2. Ruta de aprendizaje en aula invertida

## Antes de la clase

El estudiante debe:

1. Leer completa esta guía.
2. Instalar o verificar Python, si dispone de computadora.
3. Ejecutar los scripts de generación de datos.
4. Completar las tablas de resultados.
5. Responder las preguntas de autoevaluación.
6. Anotar al menos una duda concreta para la sesión presencial.

## Durante la clase

En la sesión presencial se realizará:

1. Repaso breve de conceptos.
2. Resolución de dudas sobre los ejemplos.
3. Interpretación de pruebas de bondad de ajuste.
4. Aplicación del principio de parsimonia.
5. Formulación matemática de modelos.
6. Preparación para el primer parcial.

## Después de la clase

El estudiante debe:

1. Corregir sus respuestas.
2. Guardar evidencias de ejecución.
3. Repasar las fórmulas principales.
4. Practicar con un caso nuevo.
5. Preparar su material de estudio para el primer parcial.

# 3. Marco conceptual básico

## 3.1 Formulación del problema

La formulación del problema es la primera etapa del proceso de simulación. En esta etapa se debe describir con precisión:

- El sistema real que se estudiará.
- La entidad principal del sistema.
- Las variables relevantes.
- El objetivo del estudio.
- Las preguntas que se desean responder.
- Los supuestos del modelo.

Una buena formulación evita errores posteriores. Si el problema está mal formulado, el modelo puede ser matemáticamente correcto, pero inútil para la toma de decisiones.

## 3.2 Recolección de datos

Para la Unidad II se trabajará con muestras de tamaño mayor a 30, es decir:

```
N > 30
```

Esto permite trabajar con mayor estabilidad estadística y aplicar técnicas de análisis descriptivo y pruebas de bondad de ajuste.

La recolección debe considerar:

- Variable a medir.
- Unidad de medida.
- Instrumento de medición.
- Frecuencia de recolección.
- Condiciones del sistema.
- Responsable del registro.
- Tamaño de muestra.

Ejemplo de variables:

| Sistema | Variable | Unidad |
|---|---|---|
| Fila de atención | Tiempo entre llegadas | Minutos |
| Caja de atención | Tiempo de servicio | Minutos |
| Línea de envasado | Volumen llenado | Mililitros |
| Producción | Peso de producto | Gramos |
| Servicio web | Tiempo de respuesta | Segundos |

## 3.3 Procesamiento de datos

El procesamiento incluye:

1. Revisión de datos faltantes.
2. Revisión de errores de digitación.
3. Cálculo de estadísticos descriptivos.
4. Detección de valores atípicos.
5. Evaluación de consistencia.
6. Preparación de datos para el modelo.

Estadísticos básicos:

```
Media muestral:
    x̄ = Σ x_i / n

Desviación estándar muestral:
    s = sqrt( Σ (x_i - x̄)^2 / (n - 1) )
```

## 3.4 Detección de valores atípicos con Z-Score

El Z-Score mide cuántas desviaciones estándar se encuentra un dato respecto de la media.

```
Z_i = (x_i - x̄) / s
```

Criterio sugerido para el curso:

| Condición | Interpretación |
|---|---|
| ` | Z |
| `2.5 < | Z |
| ` | Z |

En Excel puede calcularse así:

```
=ABS((B2 - PROMEDIO($B$2:$B$41)) / DESVEST.M($B$2:$B$41))
```

## 3.5 Pruebas de bondad de ajuste

Las pruebas de bondad de ajuste permiten evaluar si una muestra de datos puede provenir de una distribución teórica específica.

En esta guía se utilizará principalmente la prueba de **Kolmogorov-Smirnov**, conocida como prueba K-S.

La hipótesis general es:

```
H0: los datos provienen de la distribución propuesta.
H1: los datos no provienen de la distribución propuesta.
```

Se trabajará con nivel de significancia:

```
α = 0.05
```

Regla de decisión:

| p-valor | Decisión |
|---:|---|
| `p >= 0.05` | No se rechaza H0 |
| `p < 0.05` | Se rechaza H0 |

Interpretación recomendada:

```
Si p >= 0.05:
    No hay evidencia suficiente para rechazar la distribución propuesta.

Si p < 0.05:
    Hay evidencia suficiente para rechazar la distribución propuesta.
```

Importante: en estadística no se debe decir “se acepta H0” de manera absoluta. La expresión correcta es “no se rechaza H0”.

## 3.6 Estadístico de Kolmogorov-Smirnov

La prueba K-S compara la función de distribución empírica de los datos con la función de distribución teórica propuesta.

```
D = máx |F_n(x) - F_0(x)|
```

Donde:

```
F_n(x): función de distribución empírica de la muestra.
F_0(x): función de distribución teórica propuesta.
```

Cuanto mayor es `D`, mayor es la diferencia entre la muestra y la distribución propuesta.

## 3.7 Prueba Chi-cuadrado como referencia adicional

Además de K-S, en simulación también puede usarse la prueba Chi-cuadrado, especialmente cuando los datos se agrupan en intervalos o categorías.

```
χ² = Σ (O_i - E_i)^2 / E_i
```

Donde:

```
O_i: frecuencia observada en el intervalo i.
E_i: frecuencia esperada en el intervalo i.
```

Grados de libertad:

```
gl = k - 1 - m
```

Donde:

```
k: número de intervalos o categorías.
m: número de parámetros estimados.
```

Para esta guía, los ejemplos principales usarán K-S por ser más directa con datos continuos.

## 3.8 Formulación del modelo matemático

Un modelo matemático es una representación simplificada del sistema real mediante ecuaciones, relaciones probabilísticas o reglas de comportamiento.

La formulación del modelo debe indicar:

- Variables de entrada.
- Variables de salida.
- Parámetros.
- Supuestos.
- Ecuaciones o distribuciones.
- Condiciones de validez.

## 3.9 Principio de parsimonia

El principio de parsimonia establece que, entre varios modelos con capacidad explicativa similar, debe preferirse el modelo más simple.

En simulación:

```
Si una distribución simple ajusta adecuadamente,
no debe usarse una distribución más compleja sin justificación.
```

Ejemplo:

| Situación | Modelo recomendado |
|---|---|
| Los tiempos entre llegadas se ajustan a exponencial | Usar distribución exponencial |
| Los datos de peso se ajustan a Normal | Usar distribución Normal |
| La distribución simple no ajusta | Considerar otra distribución o modelo empírico |

## 3.10 Verificación y validación

Es importante no confundir estos conceptos.

| Concepto | Pregunta clave |
|---|---|
| Verificación | ¿El modelo fue construido correctamente? |
| Validación | ¿El modelo representa adecuadamente al sistema real? |

Verificación:

- Las fórmulas son correctas.
- Las unidades son consistentes.
- El código ejecuta sin errores.
- Los cálculos son reproducibles.
- Las condiciones matemáticas se cumplen.

Validación:

- Los resultados son coherentes con la realidad.
- Los expertos reconocen el comportamiento del sistema.
- Las salidas del modelo son comparables con datos reales.
- El modelo sirve para responder las preguntas planteadas.

# 4. Ejemplo 1: Atención en ventanilla de

# biblioteca universitaria

## 4.1 Contexto del problema

Una biblioteca universitaria tiene una sola ventanilla para atención de consultas administrativas: devolución de libros, consulta de multas, reserva de salas y trámites simples.

Los estudiantes llegan de manera aleatoria durante la mañana. Cuando la ventanilla está ocupada, los estudiantes esperan en una fila.

La jefatura de biblioteca desea saber si el sistema presenta congestión y cuánto tiempo promedio permanece un estudiante en el sistema.

## 4.2 Formulación del problema

### Sistema

Ventanilla de atención administrativa de la biblioteca.

### Entidad principal

Estudiante que solicita atención.

### Variables relevantes

| Variable | Descripción | Unidad |
|---|---|---|
| Tiempo entre llegadas | Tiempo entre la llegada de un estudiante y el siguiente | Minutos |
| Tiempo de servicio | Tiempo que dura la atención de un estudiante | Minutos |
| Número de estudiantes en sistema | Estudiantes en fila más el atendido | Estudiantes |
| Tiempo de espera | Tiempo que un estudiante espera antes de ser atendido | Minutos |

| Variable | Descripción | Unidad |
|---|---|---|
| Tiempo en sistema | Tiempo total entre llegada y salida | Minutos |

## Objetivo del estudio

Evaluar el desempeño del sistema de atención y estimar indicadores de congestión.

## Preguntas del modelo

1. ¿La ventanilla opera saturada?
2. ¿Cuál es el número promedio de estudiantes en el sistema?
3. ¿Cuál es el número promedio de estudiantes en fila?
4. ¿Cuánto tiempo promedio espera un estudiante?
5. ¿Cuánto tiempo promedio permanece un estudiante en el sistema?
6. ¿Cuál es la probabilidad de que el sistema esté vacío?

## Supuestos

Para este ejemplo se asume:

1. Existe un solo servidor.
2. La atención es individual.
3. La disciplina de atención es FIFO: primero en llegar, primero en ser atendido.
4. La población de estudiantes es suficientemente grande.
5. Los tiempos entre llegadas son independientes.
6. Los tiempos de servicio son independientes.
7. El sistema se analiza en condición estable.
8. No se consideran cierres temporales ni interrupciones del servicio.

# 4.3 Recolección de datos

Se propone una muestra de 35 observaciones para cada variable.

```
N = 35
```

Instrumento sugerido:

- Cronómetro.
- Planilla de registro.
- Observación directa.
- Registro de turnos, si existe sistema digital.

Variables a registrar:

```
Tiempo entre llegadas en minutos.
Tiempo de servicio en minutos.
```

# 4.4 Generación de datos para estudio

El siguiente script genera datos simulados reproducibles. Esto permite que todos los estudiantes trabajen con la misma base de estudio.

Archivo sugerido:

```
generar_biblioteca.py
```

Código:

```
import numpy as np
import pandas as pd

rng = np.random.default_rng(2026)

n = 35

# Tiempo medio entre llegadas: 8 minutos
tiempos_entre_llegadas = rng.exponential(scale=8.0, size=n).round(2)

# Tiempo medio de servicio: 4 minutos
tiempos_servicio = rng.exponential(scale=4.0, size=n).round(2)

df = pd.DataFrame({
    "id_estudiante": np.arange(1, n + 1),
    "tiempo_entre_llegadas_min": tiempos_entre_llegadas,
    "tiempo_servicio_min": tiempos_servicio
})

df.to_csv("biblioteca_datos.csv", index=False)

print("Datos generados correctamente.")
print(df.head())
```

Ejecución:

```
python generar_biblioteca.py
```

Resultado esperado:

Se crea el archivo:

```
biblioteca_datos.csv
```

# 4.5 Procesamiento de datos en Excel

Abrir el archivo CSV en Excel y calcular los siguientes estadísticos.

# Fórmulas sugeridas

| Métrica | Fórmula Excel |
|---|---|
| Media de tiempos entre llegadas | `=PROMEDIO(B2:B36)` |
| Media de tiempos de servicio | `=PROMEDIO(C2:C36)` |
| Desviación estándar de llegadas | `=DESVEST.M(B2:B36)` |
| Desviación estándar de servicio | `=DESVEST.M(C2:C36)` |
| Mínimo de llegadas | `=MIN(B2:B36)` |
| Máximo de llegadas | `=MAX(B2:B36)` |
| Mínimo de servicio | `=MIN(C2:C36)` |
| Máximo de servicio | `=MAX(C2:C36)` |

# Z-Score para llegadas

En una columna auxiliar:

```
=ABS((B2 - PROMEDIO($B$2:$B$36)) / DESVEST.M($B$2:$B$36))
```

# Z-Score para servicio

En otra columna auxiliar:

```
=ABS((C2 - PROMEDIO($C$2:$C$36)) / DESVEST.M($C$2:$C$36))
```

# Tabla de resultados

El estudiante debe completar una tabla como la siguiente:

| Métrica | Tiempo entre llegadas | Tiempo de servicio |
|---|---|---|
| Media | | |
| Desviación estándar | | |
| Mínimo | | |

| Métrica | Tiempo entre llegadas | Tiempo de servicio |
|---|---|---|
| Máximo | | |
| Cantidad de datos con ` | Z | > 3` |

# 4.6 Estimación de tasas

Para un modelo de colas, se estiman las tasas de llegada y servicio.

```
λ = 1 / media_entre_llegadas
```

```
μ = 1 / media_tiempo_servicio
```

Donde:

```
λ: tasa de llegada de estudiantes por minuto.
μ: tasa de servicio de estudiantes por minuto.
```

En Excel:

```
=1 / PROMEDIO(B2:B36)
```

```
=1 / PROMEDIO(C2:C36)
```

# 4.7 Prueba de bondad de ajuste para tiempos entre llegadas

Se desea evaluar si los tiempos entre llegadas pueden modelarse con distribución exponencial.

Hipótesis:

```
H0: los tiempos entre llegadas provienen de una distribución exponencial.
H1: los tiempos entre llegadas no provienen de una distribución exponencial.
```

Archivo sugerido:

```
analisis_biblioteca.py
```

Código:

```python
import pandas as pd
from scipy import stats

df = pd.read_csv("biblioteca_datos.csv")

entre_llegadas = df["tiempo_entre_llegadas_min"]
servicio = df["tiempo_servicio_min"]

alpha = 0.05

# Prueba K-S para tiempos entre llegadas
D_llegadas, p_llegadas = stats.kstest(
    entre_llegadas,
    stats.expon(loc=0, scale=entre_llegadas.mean()).cdf
)

# Prueba K-S para tiempos de servicio
D_servicio, p_servicio = stats.kstest(
    servicio,
    stats.expon(loc=0, scale=servicio.mean()).cdf
)

print("=== Prueba K-S para tiempos entre llegadas ===")
print(f"Estadístico D: {D_llegadas:.4f}")
print(f"p-valor: {p_llegadas:.4f}")

if p_llegadas >= alpha:
    print("No se rechaza H0: los tiempos entre llegadas pueden modelarse como exponencial.")
else:
    print("Se rechaza H0: los tiempos entre llegadas no deben modelarse como exponencial.")

print()

print("=== Prueba K-S para tiempos de servicio ===")
print(f"Estadístico D: {D_servicio:.4f}")
print(f"p-valor: {p_servicio:.4f}")

if p_servicio >= alpha:
    print("No se rechaza H0: los tiempos de servicio pueden modelarse como exponencial.")
else:
    print("Se rechaza H0: los tiempos de servicio no deben modelarse como exponencial.")
```

Ejecución:

```
python analisis_biblioteca.py
```

# 4.8 Interpretación de la prueba de bondad de ajuste

El estudiante debe completar:

| Variable | Estadístico D | p-valor | Decisión |
|---|---|---|---|
| Tiempo entre llegadas | | | |
| Tiempo de servicio | | | |

Preguntas de interpretación:

1. ¿Qué significa que no se rechace H0?
2. ¿Qué implica rechazar H0 para el modelo de simulación?
3. ¿Se puede usar un modelo exponencial si el p-valor es menor que 0.05?
4. ¿Qué distribución alternativa podría considerarse si la exponencial no ajusta?
5. ¿Por qué es importante no usar una distribución inadecuada?

# 4.9 Formulación del modelo matemático

Si las pruebas de bondad de ajuste indican que la distribución exponencial es razonable para tiempos entre llegadas y tiempos de servicio, puede formularse un modelo de cola M/M/1.

## Modelo M/M/1

```
M/M/1
```

Significado:

```
Primera M: llegadas con tiempos entre llegadas exponenciales.
Segunda M: tiempos de servicio exponenciales.
1: un servidor.
```

# Parámetros

```
λ = tasa media de llegadas.
μ = tasa media de servicio.
ρ = utilización del servidor.
```

# Condición de estabilidad

```
ρ = λ / μ

Debe cumplirse:

ρ < 1
```

Si:

```
ρ >= 1
```

el sistema no tiene condición estable, pues el servidor no logra atender la demanda promedio.

## Métricas del modelo M/M/1

Probabilidad de sistema vacío:

$$P_0 = 1 - \rho$$

Número promedio de estudiantes en sistema:

$$L = \lambda / (\mu - \lambda)$$

Número promedio de estudiantes en fila:

$$L_q = \lambda^2 / [\mu(\mu - \lambda)]$$

Tiempo promedio en sistema:

$$W = 1 / (\mu - \lambda)$$

Tiempo promedio en fila:

$$W_q = \lambda / [\mu(\mu - \lambda)]$$

También se cumple la Ley de Little:

$$L = \lambda W$$

$$L_q = \lambda W_q$$

# 4.10 Script para calcular métricas M/M/1

Agregar al mismo script o crear uno nuevo:

```
lambda_ = 1 / entre_llegadas.mean()
mu = 1 / servicio.mean()

rho = lambda_ / mu

if rho >= 1:
    print("El sistema no es estable. ρ debe ser menor que 1.")
else:
    L = lambda_ / (mu - lambda_)
    Lq = (lambda_ ** 2) / (mu * (mu - lambda_))
    W = 1 / (mu - lambda_)
    Wq = lambda_ / (mu * (mu - lambda_))
    P0 = 1 - rho

    print("=== Modelo M/M/1 ===")
    print(f"λ: {lambda_:.4f} estudiantes/minuto")
    print(f"μ: {mu:.4f} estudiantes/minuto")
    print(f"ρ: {rho:.4f}")
    print(f"P0: {P0:.4f}")
    print(f"L: {L:.4f} estudiantes en sistema")
    print(f"Lq: {Lq:.4f} estudiantes en fila")
    print(f"W: {W:.4f} minutos en sistema")
    print(f"Wq: {Wq:.4f} minutos en fila")
```

# 4.11 Verificación del modelo

Para verificar el modelo, comprobar:

1. Las unidades son coherentes.
2. λ y μ están en la misma unidad temporal.
3. ρ es adimensional.
4. ρ < 1.
5. L, Lq, W y Wq son positivos.
6. Se cumple la Ley de Little.

Verificación simple en Python:

```
if rho < 1:
    assert abs(L - lambda_ * W) < 1e-6
    assert abs(Lq - lambda_ * Wq) < 1e-6
    print("Verificación básica correcta.")
```

# 4.12 Validación del modelo

Para validar el modelo, se recomienda:

1. Comparar el tiempo promedio de espera estimado con observaciones reales.
2. Consultar al personal de biblioteca si los resultados son razonables.
3. Observar si la fila crece excesivamente en horas pico.
4. Revisar si los supuestos se mantienen.
5. Evaluar si el modelo responde correctamente a cambios en λ o μ.

Pregunta de validación:

```
¿El tiempo de espera calculado es coherente con lo que se observa en la biblioteca?
```

# 4.13 Aplicación del principio de parsimonia

Si la distribución exponencial ajusta adecuadamente, el modelo M/M/1 es una opción parsimoniosa porque:

- Usa pocos parámetros.
- Es fácil de interpretar.
- Permite calcular métricas analíticas.
- Es adecuado para un primer análisis.

Si la exponencial no ajusta, se debe considerar:

- Otra distribución para llegadas o servicio.
- Un modelo M/G/1.
- Un modelo basado en datos empíricos.
- Una simulación con distribución ajustada a histograma.

## 4.14 Autoevaluación del Ejemplo 1

Responda:

1. ¿Cuál es el sistema estudiado?
2. ¿Cuál es la entidad principal?
3. ¿Cuáles son las variables de entrada?
4. ¿Cuáles son las variables de salida?
5. ¿Qué supuestos se realizaron?
6. ¿Qué significa λ?
7. ¿Qué significa μ?
8. ¿Qué significa ρ?
9. ¿Qué condición debe cumplirse para estabilidad?
10. ¿Qué decisión se toma si el p-valor de K-S es menor que 0.05?

# 5. Ejemplo 2: Llenado de botellas de agua de mesa

## 5.1 Contexto del problema

Una empresa envasadora llena botellas de agua de mesa con contenido nominal de 500 ml.

El área de calidad necesita verificar si el volumen llenado se comporta de manera estable y si las botellas cumplen con las especificaciones técnicas.

Especificación:

```
Límite inferior: 490 ml
Límite superior: 510 ml
```

El problema es determinar si el proceso puede modelarse mediante una distribución Normal y qué proporción de botellas podría quedar fuera de especificación.

# 5.2 Formulación del problema

## Sistema

Línea de llenado de botellas de agua de mesa.

## Entidad principal

Botella llenada.

## Variable principal

```
Volumen llenado en mililitros.
```

## Objetivo del estudio

Evaluar si el volumen de llenado puede representarse mediante un modelo Normal y estimar el cumplimiento de especificaciones.

## Preguntas del modelo

1. ¿El proceso está centrado cerca de 500 ml?
2. ¿Existe variabilidad excesiva?
3. ¿Hay botellas atípicas?
4. ¿El volumen puede modelarse como Normal?
5. ¿Qué proporción de botellas cumple especificación?
6. ¿Qué proporción de botellas queda fuera de especificación?

## Supuestos

1. La máquina opera de manera estable durante el periodo de observación.
2. Las botellas son independientes entre sí.
3. El instrumento de medición tiene error despreciable.
4. No hay cambios de lote durante la muestra.
5. Las mediciones se realizan en condiciones normales.

# 5.3 Recolección de datos

Se propone una muestra de 40 botellas.

```
N = 40
```

Instrumento sugerido:

- Balanza calibrada, si se mide peso.
- Probeta o medidor volumétrico, si se mide volumen.
- Registro manual o digital.
- Formato de control de calidad.

Variable:

```
volumen_ml
```

Unidad:

```
mililitros
```

# 5.4 Generación de datos para estudio

Archivo sugerido:

```
generar_agua.py
```

Código:

```
import numpy as np
import pandas as pd

rng = np.random.default_rng(2026)

n = 40

# Volumen nominal: 500 ml
# Desviación estándar aproximada: 5 ml
volmenes = rng.normal(loc=500, scale=5, size=n).round(2)

df = pd.DataFrame({
    "id_botella": np.arange(1, n + 1),
    "volumen_ml": volumenes
})

df.to_csv("agua_datos.csv", index=False)

print("Datos generados correctamente.")
print(df.head())
```

Ejecución:

```
python generar_agua.py
```

Resultado esperado:

Se crea el archivo:

```
agua_datos.csv
```

# 5.5 Procesamiento de datos en Excel

Abrir el archivo CSV y calcular:

| Métrica | Fórmula Excel |
|---|---|
| Media | `=PROMEDIO(B2:B41)` |

| Métrica | Fórmula Excel |
|---|---|
| Desviación estándar | `=DESVEST.M(B2:B41)` |
| Mínimo | `=MIN(B2:B41)` |
| Máximo | `=MAX(B2:B41)` |
| Z-Score | `=ABS((B2 - PROMEDIO($B$2:$B$41)) / DESVEST.M($B$2:$B$41))` |

Tabla de resultados:

| Métrica | Valor |
|---|---|
| Media | |
| Desviación estándar | |
| Mínimo | |
| Máximo | |
| Cantidad de datos con ` | Z |
| Cantidad de datos menores que 490 | |
| Cantidad de datos mayores que 510 | |

Para contar botellas fuera de especificación:

```
=CONTAR.SI(B2:B41, "<490") + CONTAR.SI(B2:B41, ">510")
```

# 5.6 Prueba de bondad de ajuste Normal

Se desea evaluar si los volúmenes pueden modelarse con distribución Normal.

Hipótesis:

```
H0: los volúmenes provienen de una distribución Normal.
H1: los volúmenes no provienen de una distribución Normal.
```

Archivo sugerido:

```
analisis_agua.py
```

Código:

```python
import pandas as pd
from scipy import stats

df = pd.read_csv("agua_datos.csv")

volumen = df["volumen_ml"]

alpha = 0.05

media = volumen.mean()
desviacion = volumen.std(ddof=1)

# Z-Score
z_scores = (volumen - media) / desviacion
outliers = df[abs(z_scores) > 3]

# Prueba K-S Normal
D, p = stats.kstest(
    volumen,
    stats.norm(loc=media, scale=desviacion).cdf
)

print("=== Estadísticos descriptivos ===")
print(f"Media: {media:.2f} ml")
print(f"Desviación estándar: {desviacion:.2f} ml")
print(f"Mínimo: {volumen.min():.2f} ml")
print(f"Máximo: {volumen.max():.2f} ml")
print(f"Cantidad de outliers |Z| > 3: {len(outliers)}")

print()

print("=== Prueba K-S Normal ===")
print(f"Estadístico D: {D:.4f}")
print(f"p-valor: {p:.4f}")

if p >= alpha:
    print("No se rechaza H0: los volúmenes pueden modelarse como Normal.")
else:
    print("Se rechaza H0: los volúmenes no deben modelarse como Normal.")
```

Ejecución:

```
python analisis_agua.py
```

# 5.7 Interpretación de la prueba de bondad de ajuste

Tabla para completar:

| Prueba | Estadístico D | p-valor | Decisión |
|---|---|---|---|
| K-S Normal para volumen | | | |

Preguntas:

1. ¿La distribución Normal es razonable para los datos?
2. ¿Qué significa el p-valor obtenido?
3. ¿Qué decisión se toma si `p < 0.05` ?
4. ¿Qué implicancia tiene para el modelo de calidad?
5. ¿Se debería usar la Normal si se rechaza H0?

# 5.8 Formulación del modelo matemático

Si la prueba de bondad de ajuste indica que la distribución Normal es razonable, puede formularse el siguiente modelo probabilístico.

## Modelo Normal

```
X ~ N(μ, σ²)
```

Donde:

```
X: volumen llenado en una botella.
μ: media del volumen.
σ²: varianza del volumen.
σ: desviación estándar.
```

Estimadores muestrales:

$$\hat{\mu} = \bar{x}$$

$$\hat{\sigma} = s$$

Entonces:

$$X \sim N(\bar{x}, s^2)$$

# 5.9 Estandarización

La variable puede estandarizarse:

$$Z = (X - \mu) / \sigma$$

Para calcular probabilidades:

$$P(LI <= X <= LS) = \Phi((LS - \mu)/\sigma) - \Phi((LI - \mu)/\sigma)$$

Donde:

LI: límite inferior de especificación.
LS: límite superior de especificación.
Φ: función de distribución acumulada Normal estándar.

Para este caso:

LI = 490 ml
LS = 510 ml

# 5.10 Cálculo de probabilidad dentro de especificación

Agregar al script:

```
from scipy.stats import norm

LI = 490
LS = 510

probabilidad_dentro = norm.cdf(LS, loc=media, scale=desviacion) - norm.cdf(LI, loc=media, scale=

probabilidad_fuera = 1 - probabilidad_dentro

print("=== Probabilidad de cumplimiento ===")
print(f"Probabilidad dentro de especificación: {probabilidad_dentro:.4f}")
print(f"Probabilidad fuera de especificación: {probabilidad_fuera:.4f}")
print(f"Porcentaje dentro de especificación: {probabilidad_dentro * 100:.2f}%")
print(f"Porcentaje fuera de especificación: {probabilidad_fuera * 100:.2f}%")
```

Interpretación:

```
Si la probabilidad dentro de especificación es alta,
el proceso tiende a cumplir la especificación.

Si la probabilidad fuera de especificación es alta,
el proceso requiere ajuste o control.
```

# 5.11 Indicadores de capacidad del proceso

Como complemento, pueden calcularse indicadores de capacidad.

## Cp

```
Cp = (LS - LI) / (6σ)
```

## Cpk

```
Cpk = mín[(LS - μ) / (3σ), (μ - LI) / (3σ)]
```

Interpretación simplificada:

| Valor | Interpretación |
|---|---|
| `Cp < 1` | El proceso puede no cumplir especificaciones |
| `Cp ≈ 1` | El proceso está justo en el límite |
| `Cp > 1` | El proceso tiene capacidad potencial |
| `Cpk < Cp` | El proceso está descentrado |

Código:

```
Cp = (LS - LI) / (6 * desviacion)
Cpk = min((LS - media) / (3 * desviacion), (media - LI) / (3 * desviacion))

print(f"Cp: {Cp:.4f}")
print(f"Cpk: {Cpk:.4f}")
```

# 5.12 Verificación del modelo

Para verificar el modelo:

1. La media y la desviación deben tener unidades en ml.
2. Las probabilidades deben estar entre 0 y 1.
3. El porcentaje debe estar entre 0% y 100%.
4. Los valores de Cp y Cpk deben ser positivos si el proceso está dentro de límites razonables.
5. El modelo debe reproducirse con el mismo dataset.

Verificación simple:

```
assert 0 <= probabilidad_dentro <= 1
assert 0 <= probabilidad_fuera <= 1
print("Verificación básica correcta.")
```

# 5.13 Validación del modelo

Para validar el modelo:

1. Comparar el porcentaje fuera de especificación con registros históricos de calidad.
2. Consultar al responsable de planta si los valores son razonables.
3. Revisar si el proceso presenta cambios bruscos.
4. Evaluar si los datos representan la operación real.
5. Analizar si el modelo sirve para decidir ajustes de máquina.

Pregunta de validación:

```
¿El modelo Normal estimado representa adecuadamente el comportamiento real del llenado?
```

# 5.14 Aplicación del principio de parsimonia

Si la distribución Normal ajusta adecuadamente, el modelo:

```
X ~ N(μ, σ²)
```

es parsimonioso porque:

- Solo requiere dos parámetros.
- Es ampliamente conocido.
- Permite calcular probabilidades de cumplimiento.
- Facilita el análisis de capacidad.

Si la Normal no ajusta, se debe considerar:

- Transformación de datos.
- Otra distribución continua.

- Histograma empírico.
- Estimación no paramétrica.
- Revisión de causas especiales de variación.

## 5.15 Autoevaluación del Ejemplo 2

Responda:

1. ¿Cuál es el sistema estudiado?
2. ¿Cuál es la entidad principal?
3. ¿Cuál es la variable principal?
4. ¿Qué especificación debe cumplirse?
5. ¿Qué supuestos se realizaron?
6. ¿Qué significa $X \sim N(\mu, \sigma^2)$ ?
7. ¿Qué representa el Z-Score?
8. ¿Qué decisión se toma si el p-valor de K-S es menor que 0.05?
9. ¿Qué significa la probabilidad dentro de especificación?
10. ¿Qué conclusión se puede dar al área de calidad?

# 6. Comparación de los dos ejemplos

| Aspecto | Ejemplo 1: Biblioteca | Ejemplo 2: Agua de mesa |
|---|---|---|
| Sistema | Ventanilla de atención | Línea de llenado |
| Entidad | Estudiante | Botella |
| Variable principal | Tiempos | Volumen |
| Tipo de variable | Tiempo continuo | Volumen continuo |
| Distribución evaluada | Exponencial | Normal |
| Modelo formulado | M/M/1 | Normal con especificaciones |
| Objetivo | Evaluar congestión | Evaluar calidad |

| Aspecto | Ejemplo 1: Biblioteca | Ejemplo 2: Agua de mesa |
|---|---|---|
| Prueba de bondad | K-S | K-S |
| Criterio de decisión | p-valor con α = 0.05 | p-valor con α = 0.05 |

# 7. Preparación para el primer parcial

Para el primer parcial, el estudiante debe poder realizar el siguiente flujo completo:

```
Problema real
   ↓
Formulación del problema
   ↓
Identificación de variables
   ↓
Propuesta de recolección de datos
   ↓
Procesamiento de datos
   ↓
Detección de valores atípicos
   ↓
Prueba de bondad de ajuste
   ↓
Decisión sobre distribución
   ↓
Formulación del modelo matemático
   ↓
Verificación
   ↓
Validación
```

# 7.1 Competencias esperadas

| Competencia | Indicador |
|---|---|
| Formula el problema | Identifica sistema, entidad, variables, objetivo y supuestos |
| Propone datos | Define muestra mayor a 30 y variables medibles |
| Procesa datos | Calcula media, desviación, mínimo, máximo y Z-Score |
| Aplica bondad de ajuste | Plantea H0, H1, usa K-S e interpreta p-valor |
| Formula modelo | Escribe ecuaciones o distribución elegida |
| Aplica parsimonia | Elige el modelo más simple adecuado |
| Verifica | Comprueba unidades, condiciones y consistencia |
| Valida | Relaciona resultados con el sistema real |

# 7.2 Estructura recomendada para respuestas del parcial

Cuando el estudiante resuelva un caso, puede usar esta estructura:

1. Descripción del sistema.
2. Entidad principal.
3. Variables de entrada y salida.
4. Objetivo del estudio.
5. Supuestos.
6. Datos y tamaño de muestra.
7. Estadísticos descriptivos.
8. Detección de outliers.
9. Prueba de bondad de ajuste.
10. Decisión sobre la distribución.
11. Modelo matemático propuesto.
12. Fórmulas principales.
13. Verificación.
14. Validación.
15. Conclusión.

# 8. Rúbrica orientativa para estudio del parcial

Esta rúbrica es referencial y sirve como guía de preparación.

| Criterio | Excelente | Suficiente | Por mejorar |
|---|---|---|---|
| Formulación del problema | Identifica con claridad sistema, variables, objetivo y supuestos | Identifica algunos elementos | No formula claramente el problema |
| Recolección de datos | Propone muestra adecuada y variables claras | Propone datos incompletos | No define datos |
| Procesamiento | Calcula correctamente estadísticos | Calcula con errores | No procesa datos |
| Outliers | Usa Z-Score e interpreta | Usa Z-Score sin interpretación | No detecta outliers |
| Bondad de ajuste | Plantea H0/H1, interpreta p-valor correctamente | Interpreta parcialmente | No interpreta p-valor |
| Modelo matemático | Formula modelo coherente y parsimonioso | Formula modelo parcial | No formula modelo |
| Verificación | Comprueba condiciones y unidades | Comprueba parcialmente | No verifica |
| Validación | Relaciona modelo con sistema real | Relación débil | No valida |

# 9. Anexo técnico: instalación y ejecución

## 9.1 Instalación de librerías

Se recomienda usar entorno virtual.

En Windows:

```
py -m venv .venv
```

Activar entorno virtual en Windows:

```
.venv\Scripts\activate
```

Instalar librerías:

```
py -m pip install numpy pandas scipy openpyxl
```

En Debian GNU/Linux:

```
python3 -m venv .venv
```

Activar entorno virtual en Debian:

```
source .venv/bin/activate
```

Instalar librerías:

```
python3 -m pip install numpy pandas scipy openpyxl
```

## 9.2 Ejecución de scripts

Crear archivos:

```
generar_biblioteca.py
analisis_biblioteca.py
generar_agua.py
analisis_agua.py
```

Ejecutar:

```
python generar_biblioteca.py
python analisis_biblioteca.py
python generar_agua.py
python analisis_agua.py
```

Si usa Windows y el comando `python` no funciona, puede usar:

```
py generar_biblioteca.py
```

# 10. Recomendaciones finales

1. No se limite a ejecutar código. Interprete cada resultado.
2. Verifique unidades: minutos, estudiantes, mililitros, probabilidades.
3. Recuerde que `p >= 0.05` no demuestra que la distribución sea verdadera; solo indica que no hay evidencia suficiente para rechazarla.
4. Si una distribución no ajusta, no debe usarse forzosamente.
5. Prefiera modelos simples cuando expliquen adecuadamente el sistema.
6. La verificación asegura que el modelo esté bien construido.
7. La validación asegura que el modelo represente al sistema real.
8. Para el parcial, practique el flujo completo desde el problema hasta el modelo matemático.

# 11. Checklist de estudio para el primer parcial

El estudiante debería poder marcar afirmativamente cada punto:

- ☐ Puedo formular un problema de simulación.

- [ ] Puedo identificar sistema, entidad, variables y supuestos.
- [ ] Puedo proponer una recolección de datos con `N > 30`.
- [ ] Puedo calcular media y desviación estándar.
- [ ] Puedo detectar outliers con Z-Score.
- [ ] Puedo plantear H0 y H1 en una prueba de bondad de ajuste.
- [ ] Puedo interpretar el p-valor con $\alpha = 0.05$.
- [ ] Puedo decidir si una distribución es razonable.
- [ ] Puedo formular un modelo matemático simple.
- [ ] Puedo explicar el principio de parsimonia.
- [ ] Puedo diferenciar verificación y validación.
- [ ] Puedo concluir técnicamente sobre el sistema estudiado.